第08讲 Json数据抓取与处理

8.1 Json数据基本介绍

Json数据的介绍

JSON（JavaScript Object Notation）是一种轻量级的数据交换格式。JSON的主要特点是易于阅读和编写，并且易于解析和生成数据，因此广泛应用于Web服务和数据交换的领域。

Json数据的格式

JSON由对象和数组两种结构组成，对象是一组键值对（键值对之间用逗号分隔），以花括号{}括起来；数组是一组有序值（值之间用逗号分隔），以中括号[]括起来。对象和数组可以相互嵌套使用。

例如，以下是一个JSON对象的示例：

```
{
    "name": "John",
    "age": 30,
    "address": {
        "street": "Main Street",
        "city": "New York"
    },
    "books": ["1984", "Brave New World"]
}
```

该对象有四个键值对，其中键名是字符串，值可以是字符串、数字、对象、数组。

注意，所有字符串必须用双引号，而不是单引号，这是JSON的规定。

Json 数据解析

json数据本质上还是字符串信息，虽然是结构化的数据，但是直接显示的时候是一行很长的文字，非常不利于查看。所以我们可以通过对json数据进行解析，将它以结构化的形式进行展示。

解析网址：https://spidertools.cn/#/formatJSON

8.2 豆瓣电影动态页面

动态HTML技术了解

- js
    - 是网络上最常用的脚本语言,它可以收集用户的跟踪数据,不需要重载页面直接提交表单,在页面嵌入多媒体文件,甚至运行网页;

Python 网络爬虫 -- By 新雨老师

- jQuery
  - jQuery是一个快速、简洁的 JavaScript 框架,封装了 JavaScript 常用的功能代码；
- ajax
  - ajax可以使用网页实现异步更新,可以在不重新加载整个网页的情况下,对网页的某部分进行更新；

功能需求：抓取豆瓣电影中的喜剧片榜单信息。

主页链接：https://movie.douban.com/typerank?type_name=%E5%96%9C%E5%89%A7&type=24&interval_id=100:90&action=

测试代码

```
import requests

# 1、用户代理的构造
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/104.0.0.0 Safari/537.36"
}

# 2、确认目标url
url = "https://movie.douban.com/typerank?type_name=%E5%96%9C%E5%89%A7&type=24&interval_id=100:90&action="

# 3、发送网络请求，获取响应对象
response = requests.get(url, headers=headers)

# 4、保存页面数据
with open('douban_movie.html', 'w', encoding='utf-8') as f:
    f.write(response.text)
```

注：从抓取到的HTML页面中可以发现根本没有抓取到喜剧电影的榜单数据信息。

网页的种类介绍

网页可以分为动态页面和静态页面两种：

- 静态页面

  静态页面是指网页在服务器上预先生成并存储在硬盘中的一种页面，它不会做过多的交互或变化。静态页面的优点是快速、简单，对服务器资源的要求小，但是一旦生成，内容就不会改变，所以需要手动修改内容。

- 动态页面

  动态页面是指通过与服务器端交互，可以使页面内容实时变化的一种页面。动态页面通常需要依赖数据库和服务器脚本，能够无限制地改变内容。动态页面常常被用于电子商务、在线社交、论坛等需要不断更新和变化的网站。动态页面需要更多的服务器资源，但是更加灵活，能够提供更好的用户体验。

电影数据的下载

Python 网络爬虫 --- By 新雨老师

```python
import requests

# 1、用户代理的构造
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/104.0.0.0 Safari/537.36"
}

# 2、确认目标url
url = "https://movie.douban.com/j/chart/top_list?type=24&interval_id=100%3A90&action=&start=0&limit=20"

# 3、发送网络请求，获取响应对象
response = requests.get(url, headers=headers)

# 4、保存页面数据
with open('douban_movie.json', 'w', encoding='utf-8') as f:
    f.write(response.text)
```

翻页数据的动态加载

使用浏览器访问对应的域名后，服务器上的数据会响应到浏览器上进行渲染展示，但是如果数据信息较多，单页面无法全部展示，就会涉及到数据的多页展示了。

多页数据的展示一般分为两种：

- 数据页面追加

  在页面中展示数据，通过鼠标下滑到底部后触发下一页数据，然后将下一页数据追加到当前数据页的后面。

- 数据页面替换

  在页面中展示数据，通过鼠标下滑到底部后会有下一页的按钮，通过点击下一页按钮来覆盖当前展示的数据页。

豆瓣多页数据分析

因为豆瓣使用的是页面数据的追加方式，所以可以从浏览器的翻页来获取多个页面的请求链接，并分析出规律。

Python 网络爬虫 -- By 新雨老师

```
# 单页已知信息
每一个页面的请求链接中包含了20部电影的数据信息。

# 得到的页面链接
第一条：https://movie.douban.com/j/chart/top_list?
type=24&interval_id=100%3A90&action=&start=0&limit=20
第二条：https://movie.douban.com/j/chart/top_list?
type=24&interval_id=100%3A90&action=&start=20&limit=20
第三条： https://movie.douban.com/j/chart/top_list?
type=24&interval_id=100%3A90&action=&start=40&limit=20

# 分析链接的规律
每条链接中只有start参数的值不相同，因为start是每部电影的排名编号。

# 豆瓣翻页的URL规律
在链接中将start参数的值使用循环变量进行格式化替代，保证start参数是以20的倍数来进行翻页。
```

多页数据的下载

```
import time
import requests

# 1、获取抓取的数据页数
pages = int(input('请输入你想抓取的页数:'))

# 2、定义用户代理
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/104.0.0.0 Safari/537.36"
}

# 3、根据输入的抓取页数来决定循环次数
for i in range(pages):

    # 4、定义请求的url链接
    url = f"https://movie.douban.com/j/chart/top_list?
type=24&interval_id=100%3A90&action=&start={i*20}&limit=20"

    # 5、发送网络请求，获取响应对象
    response = requests.get(url, headers=headers)

    # 6、将获取到的json数据保存到文件中
    with open(f'douban_movie_{i+1}.json', 'w', encoding='utf-8') as f:
        f.write(response.text)

    # 7、提示下载成功，同时休眠3秒以方式被检测为爬虫
    print(f'第{i+1}页数据下载成功')
    time.sleep(3)
```

8.3 JsonPath介绍使用

JsonPath 是一种轻量级的查询库，可以从 JSON 文本数据中进行筛选和提取操作。有点类似于使用 XPath 在 HTML 数据中提取数据的功能。JsonPath 也可以通过使用类似于 XPath 的表达式来访问 JSON 对象中的属性和元素，并支持通配符、筛选器和函数等操作。

安装命令

```
pip install jsonpath
```

测试网站

```
https://jsonpath.com/
```

注：json 数据使用表达式筛选数据时，需要先对 json 数据进行格式化，然后再放入测试网站编写表达式筛选数据。

Jsonpath基本语法

语法命令	语法描述
$	json数据的根节点
@	json数据的当前节点
. 或 []	获取当前节点的子节点
..	选取任意位置下符合条件的数据，用于跨界点获取数据
*	获取当前节点下的所有元素
[]	迭代器标示，用于选取数组下标
[,]	迭代器中可以输入多个索引值来选择数据
?()	可以进行过滤操作
()	支持表达式计算

使用jsonpath筛选豆瓣的json数据：

```
import requests
from jsonpath import jsonpath

# 1、用户代理的构造
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/104.0.0.0 Safari/537.36"
}

# 2、确认目标url
```

Python 网络爬虫 -- By 新雨老师

```
url = "https://movie.douban.com/j/chart/top_list?
type=24&interval_id=100%3A90&action=&start=0&limit=20"

# 3、发送网络请求，获取响应对象
response = requests.get(url, headers=headers)

# 4、将响应的数据以json格式展示
json_data = response.json()
# print(json_data)  字典数据存放在列表中

# 5、对列表中的数据进行遍历
for data in json_data:
    print('==========================================================')
    # 6、对json数据进行筛选
    # 筛选出title信息,并取出值
    title = jsonpath(data, '$..title')[0]
    print('电影名称：', title)

    # 筛选电影评分
    score = jsonpath(data, '$..score')[0]
    print('电影评分：', score)

    # 筛选电影标签（列表数据）
    types = jsonpath(data, '$..types[*]')                    # 全部数据
    # types = jsonpath(json, '$..types[0,1,2]')              # 指定索引的数据
    # types = jsonpath(json, '$..types[(@.length-1)]')[0]    # 最后一个数据
    print('电影标签：', types)

    # 筛选电影演员（列表数据）
    actors = jsonpath(data, '$..actors.*')
    print('电影演员：', actors)
    print('==========================================================')
```

8.4 Json数据格式转换

json数据的格式转换是使用json模块中的 loads 和dumps 方法来进行实现。

Json 字符串 ===> json.loads() ===> Python 字典类型

Python 字典类型 ===> json.dumps() ===> Json 字符串

记忆方法：

以 Python 为中心，使用 loads 方法就可以加载到程序中, 将 json 数据转换 Python 能用的字典数据。如果不需要这个数据了就使用 dumps() 方法丢弃，将字典数据还原为 Json 数据。

测试代码

```
import json     # 这是自带的库，不需要安装
```

Python 网络爬虫 -- By 新雨老师

```python
# 打开douban.json文件，并读取其中的内容
with open('douban_movie.json', 'r', encoding='utf-8') as file:
    data = file.read()

# 读取的数据内容，是一个字符串数据
print(type(data), data)

# 使用loads方法来读取data数据，有点类似于response.json()方法
test = json.loads(data)
print(type(test), test)

# 将列表或者字典数据转换成json格式的字符串
# 如果涉及到中文数据会进行转码，通过设置ensure_ascii=False来禁止转码
demo = json.dumps(test, ensure_ascii=False)
print(type(demo), demo)
```

json 格式的参数传递

当我们发送请求时如果携带了参数，可以定义查询参数和表单参数字典，然后通过params或data来指定传递参数。

```python
requests.get(url, params={"kw": "python"})
```

但在使用post向服务器发送请求时，服务器可能会要求传递的数据必须是 json 格式，就需要通过 json 参数来自动转换格式。

```python
requests.post(url, json={"kw": "python"})
```

```python
import json
import requests


# 定义请求头
headers = {
    'content-type': 'application/json',
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/131.0.0.0 Safari/537.36',
    'cookie':'PSTM=1729230632; BDUSS=VBbFVISG1QbFFaa3ZIbllhS28xSXhUZklsROV4Z2l2ckROMkpiU2xDM3hpVGxuSVF; BDUSS_BFESS=VBbFVISG1QbFFaa3ZIbllhS28xSXhUZklsROV4Z2l2ckROMkpiU2xDM3hpVGxuSVFBQUFBJCQAAAAAAQAAAAEAAABgT0cWemxldmWfx~BFnbD;BAIDUID=4326B7A3436DB4072C80F746E1D486BD:SL=0:NR=10:FG=1;BIDUPSID=270AE4823DCA0AB9408C7CD4F46E31D3; MCITY=-158%3A;'
}

# 定义表单参数
form_data = {
    "query": "cat",
    "from": "en",
    "to": "zh",
    "reference": "",
    "corpusIds": [],
    "needPhonetic": False,
    "domain": "common",
    "milliTimestamp": 1735461170030
```

```python
}

# 定义请求的链接
url = 'https://fanyi.baidu.com/ait/text/translate'

# 自动将字典转换成json字符串，并设置content-type的值为'application/json'
response = requests.post(url, headers=headers, json=form_data)

# 手动将字典转换成json字符串，并需要在请求头中设置content-type的值为'application/json'
response = requests.post(url, headers=headers, data=json.dumps(form_data))
print(response.text)
```

Python 网络爬虫 -- By 新雨老师